

СЛАУ

Прямые и итерационные методы решения.

Цыбулин Иван (tsybulin@crec.mipt.ru)

Методы решения СЛАУ

- Прямые методы — выдают решение за фиксированное число операций
- Итерационные методы — строят последовательность *приближений* к решению.
Последовательность обрывают после достижения заданной точности.

Метод Гаусса

- Метод последовательного исключения неизвестных
- Прямым ходом приводит матрицу системы к треугольному виду, а затем находит решение полученной треугольной системы обратной подстановкой
- Для системы $n \times n$ количество арифметических действий $O(n^3)$ (примерно $\frac{2}{3}n^3$ умножений) — прямой метод.

Рассмотрим систему

$$\begin{pmatrix} 10^{-3} & 1 \\ 1 & -1 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \quad \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \approx \begin{pmatrix} 2.997003 \\ 1.997003 \end{pmatrix}$$

Будем решать ее методом Гаусса, используя в вычислениях только три значащие цифры

$$\begin{pmatrix} 10^{-3} & 1 & | & 2 \\ 1 & -1 & | & 1 \end{pmatrix} \sim \begin{pmatrix} 1 & 10^3 & | & 2 \cdot 10^3 \\ 1 & -1 & | & 1 \end{pmatrix} \sim \begin{pmatrix} 1 & 10^3 & | & 2 \cdot 10^3 \\ 0 & -10^3 & | & -2 \cdot 10^3 \end{pmatrix} \sim$$
$$\begin{pmatrix} 1 & 10^3 & | & 2 \cdot 10^3 \\ 0 & -10^3 & | & -2 \cdot 10^3 \end{pmatrix} \sim \begin{pmatrix} 1 & 10^3 & | & 2 \cdot 10^3 \\ 0 & 1 & | & 2 \end{pmatrix} \sim \begin{pmatrix} 1 & 0 & | & 0 \\ 0 & 1 & | & 2 \end{pmatrix}$$

Полученное решение значительно отличается от точного.

Данную проблему можно устранить, если в качестве ведущего элемента (того на который делится очередная строка) выбирать наибольший по модулю элемент в столбце. Такой метод называется методом Гаусса с выбором главного элемента по столбцу.

Применим его к той же системе

$$\left(\begin{array}{cc|c} 10^{-3} & 1 & 2 \\ \boxed{1} & -1 & 1 \end{array} \right) \sim \left(\begin{array}{cc|c} 0 & \boxed{1} & \color{red}{2} \\ 1 & -1 & 1 \end{array} \right) \sim \left(\begin{array}{cc|c} 0 & 1 & 2 \\ 1 & 0 & 3 \end{array} \right) \sim \left(\begin{array}{cc|c} 1 & 0 & 3 \\ 0 & 1 & 2 \end{array} \right)$$

Теперь отличие от точного решения не превосходит $3 \cdot 10^{-3}$, что оказалось даже меньше погрешности вычислений.

Почему же так происходит? Может система просто *плохо обусловлена*? Проверим.

$$\nu(\mathbf{A}, \mathbf{b}) = \frac{\|\mathbf{A}^{-1}\| \|\mathbf{b}\|}{\|\mathbf{A}^{-1} \mathbf{b}\|}$$

$$\mathbf{A}^{-1} = \frac{1}{1001} \begin{pmatrix} 1000 & 1000 \\ 1000 & -1 \end{pmatrix} \quad \mathbf{b} = \begin{pmatrix} 2 \\ 1 \end{pmatrix} \quad \mathbf{A}^{-1} \mathbf{b} \approx \begin{pmatrix} 2.997003 \\ 1.997003 \end{pmatrix}$$

$$\nu_{\infty} = \frac{2000}{1001} \frac{3}{2.997003} \approx 2.$$

Данная система *обусловлена хорошо*. Проблема в методе Гаусса. В методе Гаусса могут накапливаться *ошибки округления*.

Диагональное преобладание

Говорят, что матрица $\mathbf{A} = \{a_{ij}\}_{i,j=1}^n$ обладает (нестрогим) **диагональным преобладанием**, если

$$|a_{ii}| \geq \sum_{j \neq i} |a_{ij}|, \quad \forall i = 1, \dots, n$$

Преобладание называется строгим, если

$$|a_{ii}| > \sum_{j \neq i} |a_{ij}|, \quad \forall i = 1, \dots, n.$$

Для матриц с диагональным преобладанием в методе Гаусса без выбора ведущего элемента не происходит значительного накопления ошибок округления. Как говорят, для этих матриц метод Гаусса **вычислительно устойчив**.

Трехдиагональные системы

При решении дифференциальных уравнений нередко возникает линейная система специального трехдиагонального вида

$$\left\{ \begin{array}{lcl} b_1 x_1 & + & c_1 x_2 & = & f_1 \\ a_2 x_1 & + & b_2 x_2 & + & c_2 x_3 & = & f_2 \\ & & a_3 x_2 & + & b_3 x_3 & + & c_3 x_4 & = & f_3 \\ & & & & \ddots & & & \\ & & & & & & a_{n-1} x_{n-2} & + & b_{n-1} x_{n-1} & + & c_{n-1} x_n & = & f_{n-1} \\ & & & & & & a_n x_{n-1} & + & b_n x_n & = & f_n \end{array} \right.$$

Все уравнения имеют вид

$$a_k x_{k-1} + b_k x_k + c_k x_{k+1} = f_k, \quad k = 1, \dots, n$$
$$a_1 = c_n = 0$$

Прогонка

Для системы с трехдиагональной матрицей можно реализовать метод Гаусса, имеющий сложность $O(n)$ действий вместо $O(n^3)$. Данный метод называется *прогонкой*.

Будем искать решение в виде *прогоночного соотношения*

$$x_{k-1} = P_k x_k + Q_k,$$

где P_k, Q_k — пока не известные *прогоночные коэффициенты*.

Первое уравнение легко переписать в виде прогоночного соотношения:

$$b_1 x_1 + c_1 x_2 = f_1 \implies x_1 = -\frac{c_1}{b_1} x_2 + \frac{f_1}{b_1} \implies P_2 = -\frac{c_1}{b_1}, \quad Q_2 = \frac{f_1}{b_1}$$

Пусть мы знаем прогоночные коэффициенты до P_k, Q_k включительно.

$$x_{k-1} = P_k x_k + Q_k$$

Подставим это соотношение в уравнение с номером k

$$a_k x_{k-1} + b_k x_k + c_k x_{k+1} = f_k$$

$$a_k (P_k x_k + Q_k) + b_k x_k + c_k x_{k+1} = f_k$$

$$x_k = -\frac{c_k}{a_k P_k + b_k} x_{k+1} + \frac{f_k - a_k Q_k}{a_k P_k + b_k}$$

Мы получили рекуррентные формулы для вычисления P_{k+1}, Q_{k+1} :

$$P_{k+1} = -\frac{c_k}{a_k P_k + b_k}, \quad Q_{k+1} = \frac{f_k - a_k Q_k}{a_k P_k + b_k}.$$

Начиная с P_2, Q_2 прямым ходом прогонки можно последовательно вычислить P_k, Q_k для $k = 3, 4, \dots, n + 1$. Для последнего уравнения $c_n = 0$ и $P_{n+1} = 0$. Прогоночное соотношение для x_n принимает вид

$$x_n = Q_{n+1}.$$

Теперь обратной подстановкой можно найти остальные неизвестные:

$$x_{n-1} = P_n x_n + Q_n$$

$$x_{n-2} = P_{n-1} x_{n-1} + Q_{n-1}$$

$$\vdots$$

$$x_1 = P_2 x_2 + Q_2.$$

```
import numpy as np
```

```
def solve_tdm(a, b, c, f):
```

```
    n = len(a)
```

```
    P = np.zeros(n); Q = np.zeros(n); x = np.zeros(n)
```

```
    P[0] = -c[0] / b[0]
```

```
    Q[0] = f[0] / b[0]
```

```
    for k in range(n-1):
```

```
        P[k+1] = -c[k+1] / (a[k+1] * P[k] + b[k+1])
```

```
        Q[k+1] = (f[k+1] - a[k+1] * Q[k]) / (a[k+1] * P[k] + b[k+1])
```

```
    x[n-1] = Q[n-1]
```

```
    for k in reversed(range(n-1)):
```

```
        x[k] = P[k] * x[k+1] + Q[k]
```

```
    return x
```

```
from scipy.linalg import solve_banded
```

```
a = np.array([0, 1, 1, 1, 1, 1, 1, 1])
```

```
b = -np.array([2, 2, 2, 2, 2, 2, 2, 2])
```

```
c = np.array([1, 1, 1, 1, 1, 1, 1, 0])
```

```
f = -np.array([1, 1, 1, 1, 1, 1, 1, 1])
```

```
x = solve_tdm(a, b, c, f)
```

```
print('TDM solver: x=', x)
```

```
G = np.zeros((3, len(a)))
```

```
G[0, 1:] = c[:-1]
```

```
G[1, :] = b
```

```
G[2, :-1] = a[1:]
```

```
x_scipy = solve_banded((1, 1), G, f)
```

```
print('SciPy banded solver: x=', x_scipy)
```

TDM solver: x= [4. 7. 9. 10. 10. 9. 7. 4.]

SciPy banded solver: x= [4. 7. 9. 10. 10. 9. 7. 4.]

Матричные разложения

Довольно часто для решения систем линейных уравнений и других задач линейной алгебры применяют *матричные разложения*. Наиболее известными являются:

- $\mathbf{A} = \mathbf{LU}$, где \mathbf{L} — нижнетреугольная матрица, а \mathbf{U} — верхнетреугольная. Соответствует методу Гаусса без выбора главного элемента.
- $\mathbf{A} = \mathbf{LL}^\top$ — разложение Холецкого, применяется вместо LU для симметричных матриц.
- $\mathbf{A} = \mathbf{QR}$, где \mathbf{Q} — ортогональная, а \mathbf{R} — верхнетреугольная. Также может быть использовано для решения СЛАУ.

Эти разложения имеют сложность $O(n^3)$, как и метод Гаусса.

Другие важные разложения:

- $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}$ — сингулярное разложение, \mathbf{U} , \mathbf{V} — ортогональные, $\mathbf{\Sigma}$ — диагональная матрица из сингулярных чисел.
- $\mathbf{A} = \mathbf{S}\mathbf{\Lambda}\mathbf{S}^{-1}$ — спектральное разложение, \mathbf{S} — матрица из собственных векторов, $\mathbf{\Lambda}$ — диагональная матрица собственных чисел.

Получение таких разложений — трудоемкая задача. Более того, эти разложения получаются итерационными методами, сложность алгоритма зависит от матрицы \mathbf{A} .

Покажем, как решить линейную систему, зная LU разложение ее матрицы: пусть $\mathbf{A} = \mathbf{LU}$.

Система

$$\mathbf{Ax} = \mathbf{f}$$

может быть записана в виде:

$$\mathbf{L}(\mathbf{Ux}) = \mathbf{f}.$$

Решим сначала вспомогательную задачу с нижнетреугольной матрицей (прямой подстановкой)

$$\mathbf{Ly} = \mathbf{f},$$

а затем задачу с верхнетреугольной матрицей (обратной подстановкой)

$$\mathbf{Ux} = \mathbf{y}.$$


```

from scipy.linalg import lu, solve_triangular
def lu_solve(A, f):
    P, L, U = lu(A) #  $A = P L U$ 
    y = solve_triangular(L, P.T.dot(f), lower=True, unit_diagonal=True)
    x = solve_triangular(U, y, lower=False, unit_diagonal=False)
    return x

```

```

n = 4
x0 = np.ones(n)
A = np.random.rand(n, n)
f = A.dot(x0)
x = lu_solve(A, f)
print('x = ', x)
lu(A)

```

```
x = [ 1.  1.  1.  1.]
```

```

(array([[ 0.,  1.,  0.,  0.],
        [ 0.,  0.,  1.,  0.],
        [ 1.,  0.,  0.,  0.],
        [ 0.,  0.,  0.,  1.]]),
array([[ 1.,          0.,          0.,          0.],
        [ 0.05387288,  1.,          0.,          0.],
        [ 0.29155253, -0.49537567,  1.,          0.],
        [ 0.23474376,  0.36296334, -0.05152276,  1.] ])),

```

Итерационные методы решения СЛАУ

Итерационные методы для системы

$$\mathbf{Ax} = \mathbf{f}$$

строят последовательность приближений

$$\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \dots,$$

которая сходится к решению системы \mathbf{x}^* . Итерационным методам необходимо начальное приближение к решению \mathbf{x}_0 .

Метод простой итерации

Пусть итерационный метод строит новое приближение \mathbf{x}_{k+1} по правилу

$$\mathbf{x}_{k+1} = \mathbf{B}\mathbf{x}_k + \mathbf{F}. \quad (*)$$

Назовем \mathbf{B} *матрицей итераций*.

Отвлечемся от исходной системы $\mathbf{A}\mathbf{x} = \mathbf{f}$ и ответим на вопросы

- Когда сходится метод $(*)$, то есть когда последовательность \mathbf{x}_k стремится к какому-то \mathbf{x}^* ?
- К чему сходится метод, то есть что такое \mathbf{x}^* ?

Пусть последовательность \mathbf{x}_k сходится к некоторому \mathbf{x}^* . Тогда переходя в

$$\mathbf{x}_{k+1} = \mathbf{B}\mathbf{x}_k + \mathbf{F}$$

к пределу при $k \rightarrow \infty$, получаем

$$\mathbf{x}^* = \mathbf{B}\mathbf{x}^* + \mathbf{F}.$$

То есть, если предел \mathbf{x}_k существует, то он — решение уравнения

$$\mathbf{x}^* = \mathbf{B}\mathbf{x}^* + \mathbf{F}.$$

Рассмотрим вопрос сходимости метода простой итерации

$$\mathbf{x}_{k+1} = \mathbf{B}\mathbf{x}_k + \mathbf{F}$$

$$\mathbf{x}^* = \mathbf{B}\mathbf{x}^* + \mathbf{F}$$

Вычитая второе соотношение из первого, получаем

$$\mathbf{x}_{k+1} - \mathbf{x}^* = \mathbf{B}(\mathbf{x}_k - \mathbf{x}^*).$$

Вектор $\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}^*$ будем называть *вектором ошибки*. За одну итерацию вектор ошибки умножается на матрицу итераций \mathbf{B} .

$$\mathbf{e}_{k+1} = \mathbf{B}\mathbf{e}_k.$$

Условие $\mathbf{x}_k \rightarrow \mathbf{x}^*$ эквивалентно $\|\mathbf{x}_k - \mathbf{x}^*\| \equiv \|\mathbf{e}_k\| \rightarrow 0$. Здесь годится любая норма.

Достаточное условие сходимости

Если **какая-то** норма матрицы \mathbf{B} оказалась меньше 1, то метод простой итерации

$$\mathbf{x}_{k+1} = \mathbf{B}\mathbf{x}_k + \mathbf{F}$$

сходится при любом начальном приближении \mathbf{x}_0 и любой правой части \mathbf{F} . Действительно, пусть

$$q = \|\mathbf{B}\| < 1.$$

Тогда

$$\|\mathbf{e}_{k+1}\| = \|\mathbf{B}\mathbf{e}_k\| \leq \|\mathbf{B}\| \cdot \|\mathbf{e}_k\| = q\|\mathbf{e}_k\| \leq \dots \leq q^{k+1}\|\mathbf{e}_0\|.$$

Норма ошибки стремится к нулю как геометрическая прогрессия со знаменателем $q < 1$.

Сходимость со скоростью геометрической прогрессии называют еще *линейной сходимостью*.

Критерий сходимости

Для того, чтобы метод простой итерации

$$\mathbf{x}_{k+1} = \mathbf{B}\mathbf{x}_k + \mathbf{F}$$

сходился при любом начальном приближении \mathbf{x}_0 и любой правой части \mathbf{F} **необходимо и достаточно**, чтобы

$$|\lambda(\mathbf{B})| < 1,$$

то есть все собственные числа \mathbf{B} должны попасть в единичный круг $|\lambda| < 1, \lambda \in \mathbb{C}$.

Для симметричной матрицы

$$\|\mathbf{B}\|_E = \max |\lambda(\mathbf{B})|,$$

так что условие $\|\mathbf{B}\|_E < 1$ является не только достаточным, но и необходимым для сходимости процесса.

Как же можно по данной системе

$$\mathbf{Ax} = \mathbf{f}$$

построить итерационный процесс

$$\mathbf{x}_{k+1} = \mathbf{Bx}_k + \mathbf{F},$$

который бы сходил к решению системы?

Вспомним, что итерационный процесс сходится к решению уравнения

$$\mathbf{x} = \mathbf{Bx} + \mathbf{F}.$$

Преобразуем $\mathbf{Ax} = \mathbf{f}$ к такому виду.

Метод простой итерации с параметром

Введем вектор невязки

$$\mathbf{r}_k = \mathbf{A}\mathbf{e}_k = \mathbf{A}\mathbf{x}_k - \mathbf{f}.$$

Рассмотрим процесс с некоторым фиксированным $\tau \neq 0$.

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \tau \mathbf{r}_k$$

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \tau \mathbf{A}\mathbf{x}_k + \tau \mathbf{f} = (\mathbf{E} - \tau \mathbf{A})\mathbf{x}_k + \tau \mathbf{f}.$$

Мы получили процесс с матрицей итераций $\mathbf{B} = \mathbf{E} - \tau \mathbf{A}$ и $\mathbf{F} = \tau \mathbf{f}$, который сходится к решению

$$\mathbf{x} = (\mathbf{E} - \tau \mathbf{A})\mathbf{x} + \tau \mathbf{f},$$

что эквивалентно исходной системе.

Сходимость метода с параметром

Запишем необходимое и достаточное условие $|\lambda(\mathbf{B})| < 1$ через собственные числа матрицы \mathbf{A} .

$$\lambda(\mathbf{B}) = \lambda(\mathbf{E} - \tau\mathbf{A}) = 1 - \tau\lambda(\mathbf{A})$$

$$|\lambda(\mathbf{B})| = |1 - \tau\lambda(\mathbf{A})| < 1$$

Последнее условие показывает, что собственные числа матрицы \mathbf{A} должны лежать внутри единичного круга радиуса $\frac{1}{\tau}$ с центром в $\frac{1}{\tau}$.

Для симметричных положительно определенных матриц $\mathbf{A} = \mathbf{A}^\top > 0$ собственные числа лежат на отрезке $\lambda(\mathbf{A}) \in [\lambda_{\min}, \lambda_{\max}]$

Необходимое и достаточное условие сходимости будет иметь вид

$$0 < \lambda_{\min} < \lambda_{\max} < \frac{2}{\tau} \Leftrightarrow 0 < \tau < \frac{2}{\lambda_{\max}}$$


```
def simple_iteration(A, f, x0, tau, maxit=1000, eps=1e-6):  
    x = x0.copy()  
    it = 0  
    res = []  
    while it < maxit:  
        r = A.dot(x) - f  
        x = x - tau * r  
        res.append(np.linalg.norm(r))  
        if np.linalg.norm(r) < eps:  
            return x, res  
        it += 1  
    print('Method has not converged in %d iterations' % maxit)  
    return x, res
```

Show code

```
lambda(A) = [ 0.16969125  1.52638833 19.30392042]
```

```
tau = 0.12
```

Method has not converged in 1000 iterations



Show code

```
lambda(A) = [ 0.16969125  1.52638833 19.30392042]
```

```
tau = 0.1
```

